

Rapport d'analyse et d'interprétation

Fraude bancaire et segmentation client

1. Synthèse analytique

Ce rapport ne décrit pas seulement la démarche technique : il interprète **ce que disent les données**, **ce que signifient les modèles** et **ce qu'une organisation peut en faire**.

Constats majeurs

Sur la fraude, le jeu de données révèle un phénomène rare (environ **0,11 %** des transactions) mais structuré. Les fraudes ne se répartissent pas au hasard : elles se concentrent sur les types TRANSFER et CASH_OUT, et s'accompagnent souvent d'**incohérences entre montants et variations de soldes**. Le modèle XGBoost retenu (PR-AUC = **0,991**) classe très bien les transactions suspectes, mais cette performance doit être lue comme un **signal fort du dataset** autant qu'une garantie de performance en production.

Sur la segmentation, les clients ne forment pas des groupes parfaitement séparés (silhouette = **0,21**), ce qui est normal en marketing : les comportements évoluent progressivement. Malgré cela, **quatre profils distincts** émergent clairement et permettent des décisions actionnables : un bloc massif peu actif, un noyau premium très réactif, un segment à forte valeur plus stable, et une minorité promotionnelle/digital.

Message central pour le décideur

Domaine	Question métier	Réponse de l'analyse
Fraude	Faut-il bloquer ou surveiller ?	Prioriser le rappel ; calibrer le seuil selon la capacité humaine de traitement des alertes
Fraude	Où concentrer les contrôles ?	Sur TRANSFER / CASH_OUT et les transactions avec écarts de soldes anormaux
Marketing	Qui cibler en priorité ?	Cluster 2 (premium réactif) et Cluster 3 (forte valeur) pour la valeur ; Cluster 0 pour la réactivation

Marketing	Les segments sont-ils fiables ?	Oui pour orienter des campagnes, non comme vérité absolue — validation métier indispensable
-----------	---------------------------------	---

2. Problématique et questions d'analyse

2.1 Fraude — ce que l'on cherche à comprendre

- Quelles transactions présentent un profil atypique ?
- Le risque est-il lié au montant, au type, ou à la cohérence comptable ?
- Quel compromis accepter entre **fraudes manquées** (coût financier) et **fausses alertes** (coût opérationnel) ?

2.2 Segmentation — ce que l'on cherche à comprendre

- Existe-t-il des groupes de clients homogènes en termes de valeur, de canal et de sensibilité aux campagnes ?
- Peut-on relier chaque groupe à une stratégie marketing différente ?
- Les segments sont-ils suffisamment grands et stables pour être exploités ?

2.3 Méthodologie expérimentale

Détection de fraude

La démarche de modélisation suit une logique supervisée :

1. nettoyage initial des colonnes et suppression des doublons ;
2. construction de variables métier autour des soldes (`origin_error`, `dest_error`, `ratio montant/solde`, indicateurs de soldes nuls) ;
3. exclusion des identifiants directs (`nameOrig`, `nameDest`) et de `isFlaggedFraud` afin d'éviter une dépendance excessive à un signal déjà issu d'un système de détection ;
4. encodage de `type`, imputation et standardisation via pipeline ;
5. séparation stratifiée train/validation/test ;
6. calibration du seuil sur validation avec contrainte de rappel minimal ;
7. sélection finale sur la **PR-AUC**, plus adaptée que l'accuracy pour une classe rare.

Modèles comparés :

- régression logistique ;
- random forest ;
- XGBoost.

Segmentation client

La démarche non supervisée suit une logique de segmentation interprétable :

1. imputation de Income par la médiane ;
 2. suppression des colonnes constantes (Z_CostContact, Z_Revenue) ;
 3. création de variables métier (Age, Total_Spending, Total_Purchases, ratios par canal, Campaign_Acceptance_Total) ;
 4. encodage des catégories et standardisation ;
 5. comparaison de K-Means, clustering hiérarchique et Gaussian Mixture Model ;
 6. test de plusieurs nombres de clusters ($k = 3, 4, 5, 6$) ;
 7. choix final fondé sur un compromis entre métriques statistiques et lisibilité métier.
-

3. Analyse et interprétation — données de fraude

3.1 Un déséquilibre extrême qui change la lecture des métriques

Avec environ **1 fraude pour 920 transactions normales**, une accuracy de 99,9 % peut être obtenue en ignorant quasiment toutes les fraudes. **L'accuracy n'est donc pas une métrique décisionnelle** dans ce contexte.

Les métriques pertinentes sont :


- **Recall (rappel)** : part des fraudes réelles détectées — lié directement au montant de pertes évitées ;
- **Precision** : part des alertes qui sont de vraies fraudes — lié à la charge de travail des équipes ;
- **PR-AUC** : qualité globale du classement sur la classe rare.

Interprétation : toute évaluation du modèle doit être présentée au métier en termes de fraudes captées, fraudes manquées et volume d'alertes — pas en pourcentage d'accuracy.

3.2 Concentration du risque par type de transaction

L'EDA montre que les fraudes sont quasi absentes sur PAYMENT, CASH_IN et DEBIT, et concentrées sur :

- **TRANSFER** : taux de fraude le plus élevé (~0,65 %) ;
- **CASH_OUT** : taux plus faible mais non négligeable (~0,15 %).



de fraude par type de transaction

Interprétation métier : le risque n'est pas uniforme sur le portefeuille transactionnel. Une politique de contrôle différenciée par type de transaction est justifiée : seuils plus bas ou revue systématique sur TRANSFER et CASH_OUT, traitement allégé ailleurs.

3.3 Les soldes comme signal d'anomalie comptable

Une part importante des transactions présente des écarts entre :

- `oldbalanceOrg - amount` et `newbalanceOrig` ;
- `oldbalanceDest + amount` et `newbalanceDest`.

Les transactions frauduleuses présentent en moyenne des **écarts de solde plus marqués** que les transactions normales.

Interprétation : la fraude dans ce dataset semble souvent associée à des mouvements de fonds qui ne respectent pas la logique comptable attendue (vidage de compte, transfert vers compte vide, etc.). Les variables `origin_error`, `dest_error` et les ratios montant/solde ne sont pas de simples features techniques : elles traduisent une **hypothèse métier** — une transaction cohérente doit respecter la conservation des soldes.

3.4 Distribution des montants

Les montants sont très asymétriques (queue lourde). Les fraudes peuvent concerner des montants modestes comme très élevés.

Interprétation : un filtre basé uniquement sur le montant élevé serait insuffisant. Le modèle doit combiner montant, type et cohérence des soldes.

4. Analyse et interprétation — données clients

4.1 Structure de la base client

- **2 240 clients**, profils hétérogènes en revenu et dépenses ;
- **24 revenus manquants** sur Income — impact limité mais nécessite imputation prudente ;
- colonnes Z_CostContact et Z_Revenue constantes → sans variance, donc sans pouvoir discriminant.

Note sur les montants : les valeurs monétaires sont interprétées comme des unités du dataset. Le symbole € utilisé dans les tableaux de profils sert uniquement de repère de lecture et ne garantit pas la devise réelle des données.

4.2 Relation revenu / dépenses

La relation entre Income et Total_Spending n'est pas linéaire : certains clients dépensent proportionnellement plus que leur revenu suggère, d'autres restent en dessous de leur capacité théorique.

Interprétation : le revenu seul ne définit pas la valeur client. Le comportement d'achat (fréquence, catégories, canaux) apporte une information complémentaire essentielle pour la segmentation.

4.3 Canaux d'achat et sensibilité marketing

Les clients se répartissent différemment entre :

- achats **magasin** (canal dominant en moyenne) ;
- achats **web** ;
- achats **catalogue** ;
- achats **promotionnels**.

La variable Campaign_Acceptance_Total varie fortement d'un client à l'autre.


Interprétation : il existe bien une dimension « canal préféré » et une dimension « sensibilité aux campagnes », exploitables pour personnaliser les actions commerciales.

5. Interprétation des résultats — détection de fraude

5.1 Comparaison des modèles (lecture métier)

Modèle	PR-AUC	Recall	Precision	Seuil	Lecture
--------	--------	--------	-----------	-------	---------

Régression logistique	0,767	0,725	0,674	0,98	Baseline interprétable mais insuffisante
Random Forest	0,987	0,983	1,000	0,52	Très performant
XGBoost	0,990	0,983	1,000	0,67	Meilleur classement global ; retenu
LightGBM	0,179	0,942	0,191	0,05	Testé mais écarté : probabilités mal calibrées sur classe rare
MLP (200k lignes)	0,869	0,784	0,882	0,22	Réseau de neurones correct mais inférieur aux arbres boostés



Comparaison

des modèles de détection de fraude

Pourquoi XGBoost plutôt que Random Forest ou LightGBM ?

Random Forest atteint recall et precision identiques, mais XGBoost présente la **meilleure PR-AUC** (0,990 vs 0,987). LightGBM a été testé conformément à l'énoncé mais **échoue à calibrer les probabilités** sur cette classe rare (PR-AUC = 0,179 malgré ROC-AUC = 0,969) — il

n'est pas retenu.


Pourquoi pas le MLP ?

Le réseau de neurones (64-32, 200k lignes d'entraînement) atteint une PR-AUC de 0,869 avec un recall de 78,4 % — insuffisant face à l'objectif de détection des fraudes.

5.2 Lecture de la matrice de confusion (estimation test)

Sur le jeu de test (~157 000 transactions, ~171 fraudes) :

- **Fraudes détectées** : ~168 (recall 98,3 %) ;
- **Fraudes manquées** : 3 ;
- **Faux positifs** : 0 au seuil retenu (precision 100 %).



de confusion estimée pour XGBoost

Interprétation prudente :

Un score parfait en precision sur un seul jeu de test est **atypique en conditions réelles**. Cela peut indiquer :

1. un dataset très séparable (signaux de soldes très forts) ;
2. un seuil calibré (0,67) qui équilibre rappel et confiance ;

3. un risque de **sur-apprentissage** ou de fuite indirecte si les variables de solde reflètent mécaniquement le label.

Recommandation : valider sur une période temporelle future (step non vue) avant tout déploiement automatique de blocage.

5.3 Le seuil de décision comme choix métier

Le seuil 0,67 signifie : « alerter lorsque le modèle est suffisamment confiant tout en respectant la contrainte de rappel minimal ».

Si on baisse le seuil	Effet
Recall ↑	Plus de fraudes captées
Precision ↓ probable	Plus de fausses alertes, surcharge des analystes

Interprétation : le seuil n'est pas un paramètre technique secondaire — c'est le **traducteur entre performance statistique et politique de risque**. Il doit être recalibré avec les équipes en fonction du nombre d'alertes traitables par jour.

Chiffrage économique FP / FN


Une analyse de coût a été produite (models/fraud/fraud_cost_analysis.json) avec les hypothèses suivantes :

Hypothèse	Valeur
Coût d'une revue analyste (FP)	25 € par alerte
Coût d'un FN	Somme des montants des transactions frauduleuses non détectées (unités du dataset, lues comme EUR à titre illustratif)

Comparaison de trois seuils sur le jeu de test (171 fraudes) :

Seuil	FN	FP	Perte FN (unités)	Coût FP (€)	Coût total équivalent
0,50	3	0	~2 032 438	0	~2 032 438
0,67 (retenu)	3	0	~2 032 438	0	~2 032 438
0,84	3	0	~2 032 438	0	~2 032 438


Les 3 FN correspondent à des montants élevés (~1,4 M, ~455 k et ~182 k unités) avec probabilités quasi nulles — schémas atypiques que le modèle ne capture pas.



Lecture métier : sur ce jeu de test, le modèle ne génère **aucun FP** aux seuils testés ; le compromis se joue donc quasi exclusivement sur les **3 FN restants** (~2 M d'unités de perte illustrative). Baisser le seuil n'améliore pas le rappel ici — les FN sont des cas structurellement difficiles. En production, dès que des FP apparaissent, le coût opérationnel (25 € × nombre d'alertes) devient un levier concret pour recalibrer le seuil avec les équipes de revue.

5.4 Variables explicatives du modèle


L'importance des variables confirme que le modèle s'appuie fortement sur des signaux cohérents avec l'analyse métier : type de transaction, montants, soldes et variables dérivées d'incohérence.



des variables du modèle fraude

Interprétation : cette lecture ne remplace pas une analyse SHAP, mais elle donne déjà un contrôle de cohérence. Si les variables les plus importantes étaient des identifiants techniques ou des colonnes impossibles à connaître en production, cela signifierait un risque de fuite de données. Ici, les signaux dominants restent compatibles avec une logique opérationnelle.

L'analyse **SHAP** (échantillon de 4 000 transactions) confirme les mêmes signaux : erreurs de soldes, type de transaction et montants dominent les contributions à la probabilité de fraude.



SHAP moyenne — classe fraude

5.5 Typologie des cas difficiles (hypothèses)


Même avec un excellent modèle, certains cas restent difficiles :

- fraudes mimant des transactions légitimes (soldes cohérents) ;
- montants faibles noyés dans le bruit ;
- nouveaux schémas de fraude non représentés dans l'historique.

Interprétation : le modèle doit être vu comme un **filtre intelligent**, pas comme un substitut complet à l'expertise humaine.

5.6 Validation temporelle (step)

En complément du split aléatoire stratifié, une évaluation **temporelle** a été réalisée : entraînement sur les périodes les plus anciennes, validation et test sur des step postérieurs non vus à l'entraînement.



split aléatoire vs temporel


Lecture : si les métriques chutent nettement en split temporel, le modèle risque de mal généraliser lorsque les schémas de fraude évoluent. Cette expérience répond directement à la recommandation formulée en section 5.2.

Les détails sont exportés dans `models/fraud/fraud_temporal_metrics.json`.

5.7 Analyse des faux négatifs et quasi-faux positifs

Une analyse ciblée des erreurs a été produite sur le jeu de test (split aléatoire) :

Erreurs sur le jeu de test (seuil retenu)



Synthèse

des erreurs de classification

Type d'erreur	Enjeu métier	Action recommandée
Faux négatif (FN)	Fraude non détectée → perte financière	Analyser chaque FN pour détecter un schéma récurrent
Faux positif (FP)	Alerte inutile → coût opérationnel	Prioriser la revue humaine ; ajuster le seuil si surcharge

Les cas détaillés sont disponibles dans :

- `models/fraud/fraud_false_negatives.csv`
- `models/fraud/fraud_false_positives.csv`

Lorsque le seuil retenu (0,67) ne génère aucun FP, des **quasi-faux positifs** sont listés en abaissant le seuil à 0,50 : ce sont des transactions normales avec probabilité élevée, utiles pour anticiper la charge d'alertes si le seuil était abaissé.

5.8 Périmètre des modèles (énoncé vs implémenté)

Modèle demandé	Statut	Raison
Régression logistique	■ Implémenté	Baseline interprétable

Random Forest	■ Implémenté	Bon compromis performance / robustesse
XGBoost	■ Implémenté	Modèle retenu (meilleure PR-AUC)
LightGBM	■ Testé, ■ non retenu	Probabilités mal calibrées sur classe rare (PR-AUC 0,18)
Réseaux de neurones (MLP)	■ Testé, ■ non retenu	Recall 78,4 % — insuffisant ; entraîné sur 200k lignes
SMOTE	■ Non utilisé	Déséquilibre traité via <code>class_weight</code> / <code>scale_pos_weight</code>


XGBoost, Random Forest et LightGBM utilisent le **train complet** (~734k). Le MLP utilise **200k lignes** (coût calcul du réseau de neurones).

6. Interprétation des résultats — segmentation client

6.1 Qualité mathématique vs utilité métier

Le modèle retenu (GMM, $k = 4$) affiche :

- **Silhouette : 0,21** → séparation modérée ;
- **Davies-Bouldin : 2,42** → clusters pas parfaitement compacts ;
- **Calinski-Harabasz : 305** → structure globale présente.




PCA des clients par cluster

Interprétation : un score silhouette faible ne signifie pas que la segmentation est inutile. En marketing, les clients occupent souvent un **continuum** (du client occasionnel au client premium). L'objectif n'est pas la perfection mathématique mais la **lisibilité des personas** et leur **actionnabilité**.

Le choix de 4 clusters est justifié car il produit des profils contrastés sans fragmenter excessivement la base.


La **méthode du coude** (Elbow) sur K-Means conforte ce choix : l'inertie diminue fortement jusqu'à $k \approx 4$, puis se stabilise.



6.1bis Évaluation DBSCAN (énoncé)

DBSCAN a été testé sur une grille de paramètres ($\text{eps} \times \text{min_samples}$). La meilleure configuration ($\text{eps}=2.0$, $\text{min_samples}=10$) produit :

- **Silhouette : 0,21** (proche de GMM $k=4$) ;
- **2 clusters** seulement ;
- **91,5 % de points classés comme bruit** (-1).



Conclusion : DBSCAN est **écarté** du modèle de production car il ne fournit pas de `predict()` natif pour l'API, génère une part massive de bruit et ne produit pas de segments marketing

exploitables. Les résultats détaillés sont dans
models/clustering/clustering_dbscan_comparison.csv.

6.2 Personas interprétés

Cluster 0 — « Dormants à faible valeur » (50,5 % de la base)

Indicateur	Valeur moyenne	Lecture
Revenu	36 572 €	Moyen, mais sous-exploité
Dépense totale	124 €	Très faible
Acceptation campagnes	0,15	Quasi insensible

Interprétation : ce n'est pas nécessairement un segment « pauvre » — c'est surtout un segment **désengagé**. Le faible revenu n'explique pas à lui seul la faible dépense (comparer au cluster 1, revenu similaire mais dépenses 4× supérieures).

Enjeu : réactivation à faible coût. Campagnes massives peu coûteuses plutôt que personnalisation lourde.

Cluster 1 — « Chasseurs de promotions digitaux » (1,9 % de la base)

Indicateur	Valeur moyenne	Lecture
Revenu	49 682 €	Intermédiaire
Dépense totale	467 €	Modérée mais active
Achats web	6,98	Canal dominant
Achats promo	5,71	Très élevé
Acceptation campagnes	0,86	Très réactive

Interprétation : segment **petit mais hyper-réactif** aux offres. Comportement typique du client qui achète quand il y a une réduction, surtout en ligne. Âge moyen élevé (62 ans) : ne pas associer automatiquement « digital » à « jeune ».

Enjeu : ROI élevé sur campagnes ciblées (coupons, flash sales web). Attention au risque de **cannibalisation des marges**.

Un **protocole de campagne test A/B** (21 clients témoin / 21 clients traitement, coupon web -15 %, 4 semaines) est documenté dans [docs/CAMPAGNE_CLUSTER1.md](#) pour valider l'actionnabilité du segment avant industrialisation.

Cluster 2 — « Premium ultra-engagés » (7,8 % de la base)

Indicateur	Valeur moyenne	Lecture
Revenu	80 575 €	Élevé
Dépense totale	1 584 €	Très élevée (×12 vs cluster 0)
Achats magasin	8,28	Canal privilégié
Acceptation campagnes	2,58	La plus élevée

Interprétation : cœur de la **valeur économique**. Clients à fort pouvoir d'achat, dépenses élevées, omnicanal (magasin + catalogue), et forte réponse aux campagnes. Ce segment combine **valeur** et **réactivité** — profil rare et précieux.

Enjeu : programme VIP, relation personnalisée, avant-premières. Éviter les promotions agressives qui pourraient dégrader l'image premium.

Cluster 3 — « Fidèles à forte valeur » (39,8 % de la base)

Indicateur	Valeur moyenne	Lecture
Revenu	66 696 €	Élevé
Dépense totale	1 033 €	Élevée
Achats magasin	8,27	Canal dominant
Acceptation campagnes	0,38	Faible

Interprétation : segment **massif et rentable**, mais moins sensible aux campagnes que le cluster 2. Comportement de client fidèle qui achète régulièrement en magasin sans attendre de promotion. La dépense est élevée par **habitude**, pas par réactivité promotionnelle.

Enjeu : fidélisation, cross-sell, parcours omnicanal. Ne pas les bombarder de promotions (faible ROI, risque de lassitude).

6.3 Carte stratégique des segments

2. Mesurer mensuellement recall, precision et volume d'alertes ;
3. Analyser systématiquement les **3 fraudes manquées** (estimation test) pour comprendre les schémas non captés ;
4. Ne pas déployer de blocage automatique sans validation temporelle.

7.2 Marketing — plan d'action par segment

Segment	Taille	Priorité	Action clé	KPI de succès
0 — Dormants	1 132	Moyenne	Réactivation email/promo légère	Taux de réactivation
1 — Promo digitaux	42	Haute (ROI)	Coupons web personnalisés	Taux de conversion promo
2 — Premium réactifs	175	Critique	Programme VIP	CLV, fréquence achat
3 — Fidèles stables	891	Critique	Cross-sell omnicanal	Panier moyen, rétention

7.3 Prédiction et déploiement

Le projet dispose déjà d'une couche de prédiction exploitable :

- **Dashboard Streamlit** : permet de visualiser les résultats, tester une transaction et attribuer un segment à un client ;
- **API FastAPI** : expose les endpoints /predict/fraud et /predict/segment ;
- **Modèles sauvegardés** : les pipelines joblib incluent preprocessing + modèle, ce qui limite le risque d'incohérence entre entraînement et inférence.

Exemple de sortie attendue — fraude

```
{ "prediction": 1, "probability": 0.92, "threshold": 0.67, "model": "xgboost" }
```

Lecture métier : une transaction avec une probabilité supérieure au seuil est envoyée en alerte prioritaire. La probabilité permet aussi de trier les alertes par urgence.

Exemple de sortie attendue — segmentation

```
{ "segment": 2, "model": "gmm_k4", "n_input_features": 39 }
```

Lecture métier : le segment doit être relié à la table de personas. Par exemple, le segment 2 correspond aux clients premium ultra-engagés et appelle une stratégie VIP/personnalisée.

Architecture de déploiement

Brique	Rôle	Technologie actuelle
Dashboard	Démonstration, analyse et prédiction interactive	Streamlit
API	Scoring programmé par requête HTTP	FastAPI
Modèles	Artefacts d'inférence	joblib
Données	Sources brutes (Git LFS pour fraude)	CSV
Conteneurisation	Reproductibilité locale / serveur	Docker + docker - compose
CI/CD	Tests automatiques à chaque push	GitHub Actions
Monitoring MVP	Vérification artefacts et seuils	scripts/check_ml_health.py
Monitoring cible	Drift et suivi temporel	Evidently AI / MLflow (roadmap)

Démarrage local conteneurisé :

```
docker compose up --build
```

8. Limites, biais et prudence interprétative

8.1 Fraude

Limite	Impact sur l'interprétation
Dataset potentiellement synthétique ou très structuré	Performance peut être optimiste vs production
Validation temporelle complémentaire réalisée	Écart modéré vs split aléatoire — à confirmer sur périodes futures

Variables de soldes très prédictives	Si qualité des soldes dégradée en prod, performance chute
Chiffrage FP/FN basé sur hypothèses	Coût FP fixé à 25 €/alerte ; montants FN en unités dataset — à recalibrer avec le métier
isFlaggedFraud exclu	Correct méthodologiquement, mais le modèle ne reproduit pas le système existant

8.2 Segmentation

Limite	Impact sur l'interprétation
Silhouette modérée (0,21)	Frontières entre clusters floues — certains clients sont « entre deux »
Cluster 1 très petit (42)	Statistiques instables ; protocole A/B documenté pour test prudent
Pas d'historique temporel	Segments peuvent évoluer ; recalcul périodique nécessaire
Response exclu du clustering	Le modèle ne prédit pas directement la conversion future

8.3 Biais généraux

- **Biais de sur-confiance** : des métriques excellentes peuvent masquer un dataset trop facile ;
- **Biais de staticité** : les profils sont une photographie, pas une vidéo ;
- **Biais d'action** : un segment n'est utile que si une action concrète lui est associée.

9. Conclusion analytique

Ce que les données nous apprennent

La fraude est un phénomène rare, concentré et structurellement détectable — surtout via les incohérences de soldes et les types de transaction à risque.

Les modèles avancés (XGBoost) apportent un gain réel par rapport à une baseline logistique, mais le choix du seuil reste un arbitrage métier, pas un choix statistique pur.

La base client n'est pas homogène : quatre personas distincts émergent, avec des logiques économiques différentes (dormance, chasse aux promos, premium réactif, fidélité stable).

La segmentation marketing et la détection de fraude répondent à des logiques opposées

: en fraude, on cherche la rareté et l'anomalie ; en marketing, on cherche la régularité et la ressemblance. Les deux démarches sont complémentaires.

Ce qui reste à confirmer

L'analyse actuelle permet de formuler des recommandations, mais plusieurs points méritent une validation supplémentaire avant toute généralisation :

- **Robustesse dans le temps** : une validation temporelle complémentaire a été réalisée ; le suivi sur de nouvelles périodes step reste nécessaire en production.
- **Actionnabilité des segments** : un protocole de campagne test A/B est prêt pour le cluster 1 ; les clusters 0 et dormants restent à valider par des actions terrain mesurées.
- **Stabilité des personas** : sans recalcul périodique, on ne sait pas si les quatre segments restent valides ou si les clients migrent d'un profil à l'autre au fil des trimestres.